

راهنمای استفاده از دیتاست و آشنایی با سیستم‌های توصیه‌گر

۱. هدف این راهنما

هدف از این راهنما، فراهم کردن یک توضیح مفهومی و کاربردی درباره:

- دیتاست مورد استفاده در تمرین (MovieLens 100K)
 - ساختار داده‌ها و نقش هر فایل
 - مفهوم سیستم‌های توصیه‌گر
 - نحوه‌ی استفاده از داده‌ها در چارچوب تمرین الگوریتم‌های تکاملی است.
- مطالعه‌ی این راهنما برای درک صحیح مسئله و پیاده‌سازی درست الگوریتم توصیه می‌شود.

۲. معرفی دیتاست MovieLens 100K

در این تمرین از دیتاست MovieLens 100K استفاده می‌شود که یکی از دیتاست‌های استاندارد و پرکاربرد در حوزه‌ی سیستم‌های توصیه‌گر است.

این دیتاست شامل:

- 100,000 امتیازدهی
- توسط 943 کاربر
- روی 1682 فیلم

می‌باشد.

هر کاربر حداقل به ۲۰ فیلم امتیاز داده است که این موضوع باعث می‌شود داده‌ها برای یادگیری الگوهای رفتاری کاربران مناسب باشند.

۳. توضیح فایل‌های دیتاست

۱.۳. فایل **u.data** — تعاملات کاربر و فیلم

این فایل شامل داده‌های اصلی مربوط به امتیازدهی کاربران به فیلم‌ها است. هر سطر دارای چهار ستون است:

- **user_id**: شناسه‌ی کاربر
- **item_id**: شناسه‌ی فیلم
- **rating**: امتیاز داده‌شده (بین ۱ تا ۵)
- **timestamp**: زمان ثبت امتیاز به صورت *Unix time*

هر سطر بیانگر یک تعامل کاربر-فیلم است.

در این تمرین، این فایل برای آموزش مدل پایه‌ی توصیه‌گر و همچنین برای ارزیابی عملکرد توصیه‌ها استفاده می‌شود.

۲.۳. فایل **u.item** — اطلاعات فیلم‌ها و ژانرها

این فایل اطلاعات محتوایی مربوط به فیلم‌ها را شامل می‌شود. هر سطر نشان‌دهنده‌ی یک فیلم است و شامل:

- شناسه و عنوان فیلم
- تاریخ انتشار
- لینک IMDb
- ۱۹ ستون دودویی ژانری

در ستون‌های ژانری:

- مقدار **1** به معنی تعلق فیلم به آن ژانر است
- مقدار **0** به معنی عدم تعلق است

یک فیلم می‌تواند هم‌زمان به چند ژانر تعلق داشته باشد.

در این تمرین، اطلاعات ژانری برای:

- محاسبه‌ی تنوع توصیه‌ها
- اعمال قیود تنوع ژانری
- تحلیل کیفی نتایج

استفاده می‌شود.

۳.۳. فایل u.genre — فهرست ژانرها

این فایل نگاشتی بین شناسه‌ی عددی ژانرها و نام آن‌ها ارائه می‌دهد (مانند Drama, Comedy, Action و ...). این فایل عمدتاً برای نمایش و تفسیر نتایج مورد استفاده قرار می‌گیرد.

۴.۳. فایل u.user — اطلاعات کاربران

این فایل شامل اطلاعات جمعیت‌شناختی کاربران (سن، جنسیت، شغل و کد پستی) است.

در این تمرین:

- این اطلاعات مستقیماً در الگوریتم توصیه‌گر استفاده نمی‌شود
- اما می‌تواند مبنایی برای تحلیل‌های پیشرفته‌تر یا استفاده از آن در روش پیشنهادی دانشجویان باشد

۴. سیستم توصیه‌گر چیست؟

سیستم توصیه‌گر (*Recommender System*) سیستمی است که هدف آن پیشنهاد آیتم‌های مناسب به کاربران بر اساس داده‌های گذشته است.

در کاربردهای واقعی:

- Netflix فیلم پیشنهاد می‌دهد
- Spotify موسیقی پیشنهاد می‌دهد

- Amazon محصول پیشنهاد می دهد

هدف اصلی:

ارائه ی فهرستی از آیتم ها که احتمالاً مورد علاقه ی کاربر خواهند بود.

۵. نقش مدل پایه (Matrix Factorization)

در این تمرین از **Matrix Factorization (MF)** به عنوان مدل پایه استفاده می شود.

این مدل با استفاده از داده های **u.data** برای هر زوج (کاربر، فیلم) یک امتیاز پیش بینی شده تولید می کند.

نکته ی مهم:

دانشجویان نیازی به تغییر یا بهبود مدل **MF** ندارند.

مدل **MF** صرفاً به عنوان:

- منبع امتیازدهی
- و مبنای محاسبه ی دقت (Accuracy) در نظر گرفته می شود.

۶. از پیش بینی امتیاز تا فهرست توصیه

در عمل، سیستم توصیه گر باید:

- برای هر کاربر یک فهرست محدود (مثلاً **Top-10**) از فیلم هایی که قبلاً مشاهده نکرده است تولید کند.

بنابراین، مسئله ی اصلی تمرین این است:

چگونه از میان آیتم های کاندید، یک فهرست توصیه ی مناسب انتخاب کنیم؟

۷. چرا تنوع اهمیت دارد؟

اگر تنها معیار انتخاب فیلم‌ها امتیاز پیش‌بینی شده باشد:

- ممکن است همه‌ی فیلم‌ها از یک ژانر باشند
- تجربه‌ی کاربر یکنواخت شود
- سیستم توصیه‌گر ضعیف به نظر برسد

به همین دلیل، در این تمرین:

- دقت (Accuracy) و
- تنوع (Diversity)

به‌صورت هم‌زمان در نظر گرفته می‌شوند.

۸. مسئله به‌عنوان یک مسئله‌ی بهینه‌سازی چندهدفه

در این تمرین:

- فضای جستجو: فهرست‌های توصیه‌ی Top-K
- اهداف:

○ بیشینه‌سازی دقت

○ بیشینه‌سازی تنوع

- قید: حداقل پوشش ژانری

این ویژگی‌ها باعث می‌شود مسئله به‌طور طبیعی یک مسئله‌ی بهینه‌سازی چندهدفه باشد.

۹. نقش الگوریتم‌های تکاملی و ازدحامی

الگوریتم‌های تکاملی و ازدحامی به‌دلیل:

- توانایی جستجو در فضاهاى پیچیده

- عدم نیاز به گرادیان

- انعطاف پذیری در تعریف اهداف و قیود

برای حل این مسئله بسیار مناسب هستند.

در این تمرین، وظیفه‌ی الگوریتم انتخابی شما:

یافتن یک فهرست توصیه‌ی Top-K است که تعادل مناسبی بین دقت و تنوع ایجاد کند.

۱۰. جمع‌بندی

این تمرین با استفاده از دیتاست MovieLens 100K:

- یک مسئله‌ی واقعی سیستم‌های توصیه‌گر را مدل‌سازی می‌کند

- آن را به یک مسئله‌ی بهینه‌سازی چندهدفه تبدیل می‌کند

- و بستری مناسب برای کاربرد عملی الگوریتم‌های تکاملی فراهم می‌آورد

تمرکز اصلی تمرین بر:

- طراحی نمایش راه‌حل

- تعریف تابع هدف

- مدیریت قیود

- و تحلیل رفتار الگوریتم

است.